汉字字谜能否成为大语言模型的结构探针？

——基于生成–求解闭环、2×2 全因子与 ICL 控制任务的有效性裁定

作者：春芽数源（机构署名）　　机构：Spring Buds Data Source Inc.　　日期：2026-11-06　　公开版：2026-11-09（配套数据集 CCRP DataSet v0.1）

目录

摘要

1 引言

2 相关工作

3 判据驱动的研究设计与数据基础

4 实验一：生成–求解闭环

5 实验二：ICL 控制任务

6 综合裁定：字谜能否成为结构探针

7 局限

8 结论

参考文献

附录 A　数据口径与可复现性

附录 B　2×2 可加分解推导

附录 C　典型案例索引

> 本文定位：本文回答一个可判定的方法论问题——汉字字谜在何种条件下能作为大语言模型的结构探针。研究为 API 调用层面的零权重修改实验；不包含任何训练、微调或梯度更新实验，第 6.4 节关于「训练该补什么」的内容全部明确标注为假设。本文不报告模型能力排名。

摘要

汉字字谜要求把单字当作可分解、可重组的结构化对象并逆向搜索，答案恰为一个汉字、判分客观，因而常被当作检验大语言模型（LLM）汉字知识的任务。但它能否成为一支结构探针——即一个读数可归因于目标能力、而非题目分布或评测协议本身的工具——此前没有明确判据。本文先给出行为层结构探针的六条有效性判据（客观判分 C1、结构化可分解 C2、信息条件可控 C3、选择性与对照 C4、能力层可区分 C5、可复现可审计 C6），再用三套递进实验逐条检验：零样本解谜基线、生成－求解闭环（597 条自创谜题，由制谜方本人在相隔一天的全新单轮对话中作答）、ICL 控制任务（24 题 × 4 条件 × 2 模型 = 192 次调用，同批示例谜面仅替换 `assistant` 推理内容来源）。

主要结果：交叉盲测猜中率 39.0%（233/597），同题自测升至 44.2%（264/597），逐题配对 McNemar 精确检验 p=0.0144；但按制谜方分层出现方向相反的差异（kimi +21.5 pp，u2 −11.0 pp，均显著）。这是混淆而非矛盾：制谜方 × 猜题方恰好构成近似 2×2 全因子，可加分解给出猜题能力差 β =+16.26 pp、题源难度差 α =+11.36 pp 与自我熟悉净效应 γ =+5.22 pp，后者在平衡设计下恒等于总体差值（实测 +5.19 pp，0.03 pp 差异来自 298/299 的组不平衡）；即两家模型共享同一个自我优势，表观符号被猜题能力差翻转。四格诊断进一步显示 273 条两方皆错、91 条仅自测对、60 条仅交叉对：模型在持有答案、字理卡与跨字示例时能写出合理的解谜叙述，撤去这些条件后却无法稳定逆向执行，呈现生成－理解的程序性不对称。两处不支持强解释的负面结果亦如实报告：仅自测对与仅交叉对的拆形占比差异 Fisher p=0.245；出题推理文本含谜底字的比例差异 p=0.066。

ICL 控制任务无任何统计显著结果（所有 McNemar p≥0.125），却提供一个干净的天然对照：kimi 自写的 4 条示例解释全部正确，其 `self` 条件与人工程序示例持平（45.8%）；u2 自写解释中有一条把「旭日初升」误拆为「旭去日＝九」，其 `self` 条件降至 20.8%，比零样本低 16.7 pp，`program` 对 `self` 配对为 4:0。据此，示例效果取决于推理内容是否可执行且正确，而非是否出自模型自身。

综合裁定是有条件的肯定：C1/C2/C6 完全满足；C3/C4 在自建闭环题集上满足、却被现成公开切片否决（100 题仅 11 个答案字、85 题来自公开 train/valid、test 15 题答案全为「旦」、四家推理预算不对等）；C5 只有方向性证据。因此字谜能作为诊断型结构探针，不能在现有题集上作为排名型基准，作为训练信号探针则尚不能判定。本文给出补齐 C3/C4/C5 的协议建议，并把训练价值严格限定为三条可证伪假设与三类已实证的数据风险。

关键词：汉字字谜；结构探针；大语言模型；控制任务；选择性；程序性知识；生成－求解不对称；自我偏好；上下文学习；评测效度

1 引言

1.1 字谜为什么有资格被当作结构探针

大多数中文 NLP 评测把汉字当作词元序列中的原子单位。汉字字谜却强制要求相反的操作：给定一个自然语言谜面，求解者须把目标字还原为部件、笔画、读音与义项的组合结构，并执行「取半、增删、并置、别解、谐音转调」等一系列可逆操作，最终收敛到唯一的一个汉字。以本文实验中的一条谜面为例：

> 「叉去一点，添上一寸」→ 对（「叉」去一点得「又」，并置「寸」）

这一任务有三个对探针设计极为有利的性质。其一，答案是单个汉字，判分为精确字符串匹配，无需 LLM-as-judge、无需人工评分、无需主观量规，从而把「测量工具本身的偏差」压到最低。其二，字形操作是离散且可验证的，一条推理链要么确实能从谜面走到谜底，要么不能，可以逐条审计；且字形、语义、音韵三类线索可被正交地指定。其三，生成与求解互为逆过程：出题是从（字 + 字理 + 手法）到谜面，猜题是从谜面回到字，二者构成可控闭环，允许我们操纵「谁出题、谁猜、上下文里给什么」来分离能力成分。

CC-Riddle（Xu et al., 2022/2023）最早把这一任务系统化，构建了人工谜面与模型生成谜面混合的问答数据集，并报告 BERT、ChatGPT、ChatGLM 均表现不佳。近年的谜题推理评测（如 RiddleBench, Halder et al., 2025）进一步把谜题用作诊断工具，观察到幻觉级联、自我确认偏差与推理脆弱性。但已有工作大多沿用一个隐含前提：把字谜当作一道题，用得分高低衡量模型。若改问「字谜能否成为探针」，需要回答的就不是分数，而是：这个读数究竟测到了目标能力，还是测到了题目分布、提示格式与评测协议？

1.2 「探针」不等于「基准」：六条有效性判据

必须先澄清术语。probing 文献中的 structural probe 指以模型内部表征为输入、用线性变换检验句法树距离是否被编码（Hewitt & Manning, 2019）；本文的「结构探针」是行为层探针（behavioral probe）：用一个结构化、可判分、信息条件可控的外部任务去诊断模型能力。我们不对隐藏状态作任何探测，也不宣称定位到具体层或神经元。但表征层 probing 提出的方法论要求对行为层同样成立，甚至更为关键——Hewitt & Liang（2019）指出，探针必须配合控制任务（control task）才具选择性（selectivity），否则高读数可能只是探针自身学会了任务；Belinkov（2022）系统梳理了基线、度量、分类器选择与相关性解释等方面的陷阱。

据此，本文把「字谜能否成为结构探针」拆成六条可判定的判据：

表 1　行为层结构探针的六条有效性判据

判据	要求	违反时的典型伪影	检验位置
C1 客观可判分	答案唯一可验证，不依赖评判者或量规	LLM-as-judge 自我偏好、评分漂移	§3.2、§4.2
C2 结构化可分解	任务可拆为正交的原子操作维度，以便定位缺口	只有一个总分，无法区分字形 / 语义 / 音韵	§3.4、§4.3
C3 信息条件可控	能构造「持有答案 / 不持有答案」的隔离对照，且题集无记忆污染	公开集泄漏、答案先验、按答案字聚集	§3.3–3.4、§4.1
C4 选择性（控制任务）	得分变化可归因于目标能力，而非格式、示例风格、提示长度或猜题能力主效应	把 few-shot 格式效应、模型强弱差误读为能力	§4.4、§5.1
C5 能力层可区分	能区分「权重里已有、缺格式对齐」与「需权重层注入」	由单次准确率直接推断训练方案	§5（仅方向性）
C6 可复现可审计	冻结题集、固定 prompt 版本、逐题留存、溯源分级	无法复算、无法排除伪造来源	§5.4、附录 A

六条判据构成一个判别框架：C1 – C2 决定「有没有资格」；C3 – C4 决定「读数是否可归因」，是探针与基准的分水岭；C5 决定「能否外推到训练」；C6 决定「结论能否被复核」。第 6.1 节将逐条给出裁定。

1.3 研究问题与贡献

把上述判据应用于字谜，得到三个可回答的经验问题：

- RQ1（可逆性，对应 C2/C5）：模型在持有答案与字理信息时写出的解谜叙述，是否对应一条在只给谜面时仍可执行的求解程序？若否，缺口位于「知识表征」还是「程序执行」？
- RQ2（选择性，对应 C4）：把同一批谜题交回制谜方本人（全新会话、不携带出题记忆），猜中率是否上升？该上升是「自己更懂自己的谜」，还是「谁更会猜」这一主效应造成的假象？能否在客观判分任务上把它量化并分离？
- RQ3（可激活性，对应 C5）：若不改动权重、只在上下文里给不同质量的解谜示例，哪些能力被激活、哪些纹丝不动？由此能否对「训练该补什么」提出可证伪的推断？

三套实验分别见第 3.3、4、5 节，综合裁定见第 6 节。本文贡献如下：

1. 提出行为层结构探针的六条判据并完成逐条裁定。结论不是简单的「能 / 不能」，而是分场景的：诊断型成立、排名型在现有题集上不成立、训练信号型待定（表 16、表 17）。
2. 提出生成 – 求解闭环并完成 2×2 全因子分离。597 条同题配对实验给出自我熟悉净效应 γ =+5.22 pp（配对 McNemar p=0.0144）；证明按制谜方分层时「方向相反」是猜题能力主效应 β 翻转符号所致。与已有 self-preference 研究（Zheng et al., 2023；Halder et al., 2025）多基于主观打分不同，本设定判分完全客观、效应可加分解、且给出识别条件。
3. 给出生成 – 理解不对称的四格证据与诚实的负面结果。273 条两方皆错（会意+谐音占 79.9%，高于总体 67.0%）、91 条仅自测对、60 条仅交叉对，制谜方归属在两格间差异极显著（Fisher

$p=1.65\times10^{-12}$）；同时报告两处不支持强解释的检验（$p=0.245$、$p=0.066$）。

4. 以「同谜面、仅换推理来源」的 ICL 控制任务给出监督质量的天然对照。kimi 自写示例全对、u2 自写示例含 1 条字形误拆，二者 `self` 相对 `program` 的表现恰好分叉（持平 vs −16.7 pp），把「示例推理的正确性」与「示例来源的自我性」分离开来。

1.4 一个必须前置声明的边界

本文不报告模型能力排名。第 3.3 节用自身数据说明：现成的 100 题切片与公开数据集的完整分布均不具备排名效度（11 个答案字、85 题来自公开 train/valid、test 15 题答案全为「旦」、四家推理预算不对等）。因此下文所有百分比只用于同一批题目上的条件间配对比较，绝不用于跨模型优劣宣称。数据集审计在本文中被降级为方法学证据与局限，其作用是否决 C3/C4，而非构成本文主线。

---

2 相关工作

汉字字谜数据集与任务。 Xu、Zhang 与 Wan（2022，2023 修订）发布 CC-Riddle，以网络爬取 + 生成模型 + 人工过滤构建，覆盖大部分常用简化字，并用检索式、生成式与多选式三种问答策略测试 BERT、ChatGPT、ChatGLM，发现现有模型难以解字谜。该数据集是当前工作的数据底座；其公开 train/valid/test 划分与「按答案字聚集」的排列方式，是本文第 3.3 节效度审计的对象。

探针方法论、控制任务与选择性。 Hewitt & Manning（2019）提出 structural probe，检验句法树是否嵌入词表示空间的线性变换；Hewitt & Liang（2019）随即指出高探针准确率可能来自探针自身记忆了词型，主张用随机标签的 control task 度量 selectivity；Belinkov（2022）进一步综述了基线、度量、分类器选择与「相关性不等于因果」等方法论问题。这些工作都以内部表征为对象。本文把同一套要求迁移到行为层：把「同一批题、同一判分器、只换一个条件」当作控制任务，把「生成方 × 评估方」的 2×2 交叉当作选择性的识别策略，把 ICL 四条件当作对格式效应的显式控制。据我们所知，这是首次把 control-task 逻辑用于汉字结构化操作的行为诊断。

谜题作为推理诊断工具。 Halder et al.（2025）的 RiddleBench 收录 1,737 道英文谜题，发现即使强模型也仅略高于 60%，并报告幻觉级联、错误固着、自我确认偏差（self-confirmation bias）以及约束重排下的脆弱性。与本文最接近的是「自我确认」这一发现，但 RiddleBench 的判分依赖推理链评估与模型自评，本文则在单字精确匹配上量化同类现象，并通过 2×2 设计把它与猜题能力分离。

记忆污染与「推理还是记忆」。 Hu et al.（2026）以语言学家新创的中文歇后语构造无污染集，用低频既有项与新创项的准确率差 Δacc 作为记忆指标，发现中文前沿模型平均下降 23.6 pp 而英语中心模型仅 5.1 pp，并观察到「模型创作质量显著低于人类」。本文与该工作在「需要无污染题集」上结论一致，但诊断路径不同：我们不依赖「新造题 vs 旧题」的难度匹配，而是让模型自己造题、再由自己在全新会话中作答，从而在同一批题上实现配对控制；此外本文把生成侧与求解侧同时纳入观察。

自我偏好与 LLM-as-judge。 Zheng et al.（2023）在 MT-Bench / Chatbot Arena 上系统记录了位置偏差、冗长偏差与 self-enhancement bias，并谨慎指出数据不足以断定该偏差存在。此后大量工作沿主观评分或偏好对扩展这一方向。本文的差异点在于：不存在评判者、不存在偏好对、不存在量规，只有

一个可与标准答案比对的单字输出；因此观测到的 +5.22 pp 是求解成功率之差，不是评分倾向之差。

上下文学习与程序性知识。 Brown et al.（2020）确立 few-shot 上下文学习，Wei et al.（2022）表明链式推理示例可激发多步推理。本文沿用 knowing-that / knowing-how 的经典区分（Ryle, 1949）来表述核心现象：模型能描述「木 + 目 = 相」，未必能在只有谜面时执行反向搜索。ICL 在此被用作控制任务兼无需改权重的虚拟训练，其增益方向用于区分「格式对齐缺口」与「权重层能力缺口」（第 6.4 节）。

---

3 判据驱动的研究设计与数据基础

3.1 三套探针总览

表 2　本文三套实验、识别逻辑与所检验的判据

探针	数据规模	操纵变量	识别目标	判据	主要统计
P0 零样本解谜基线	100 题（四模型前置评测）+ 597 题（交叉盲测）	无	基线可解性、手法难度、效度审计	C1 C2 C3	Wilson 95% CI、分层率
P1 生成–求解闭环	597 题 × 2 条件 = 1,194 次作答	猜题方 = 对方 / 本人；会话全新	自我熟悉净效应、生成–理解不对称	C2 C3 C4 C5	逐题配对 McNemar、2×2 可加分解、Fisher
P2 ICL 控制任务	24 题 × 4 条件 × 2 模型 = 192 次调用	`assistant` 推理内容来源	能力可激活性、监督信号质量	C4 C5	配对 McNemar、方向性对照

三套探针共用同一套系统提示、用户模板、输出解析与判分器（`riddle_eval_hy4` 的 `SYSTEM_PROMPT` / `USER_TEMPLATE` / `parse_response` / `normalize_gold`），判分统一为去空白后的单字精确匹配。这保证跨实验的数字可比，也是本文能把 P1 的 `cross` 条件与 P2 的 `zero` 条件直接对照的前提。需说明 P1 的 `cross` 条件即复用 P0 的 597 次交叉盲测作答，并非另跑一批；P1 新增的是 597 次 `self` 作答。

3.2 模型与调用协议

参与闭环实验的是两个可用的中文商用 API：kimi-k3.1-pro（下文记作 K）与 u2-flash（记作 U）。另有 hy4 与 deepseek-v4-pro（DS）参与了 11-04 的 100 题前置评测与 11-05 的 120 题高档位标定，但因账户额度返回 HTTP 402，未参与 P1/P2 的任何调用。本文不因此推断这两家模型的能力。

关键调用协议：

- 全新单轮对话：P1 自测的每条谜题各占一次独立 API 调用，`messages` 恰为 `[system, 单条 user]`，`history_messages=0`，不携带谜底、字理卡、出题推理、跨字示例或任何前序轮次；出题在

2026-11-05 的独立进程，答题在 2026-11-06 的新进程。凭证字段 `conversation.mode="fresh_single_turn"` 全库唯一，`maker==guesser` 对 597/597 成立。

- 提示词与采样参数：同一 `prompt_version`（`riddle-gen-skill-v0.2-full100`），3 并发、指数退避处理 429/超时、单题超时 180 s、重试 2 次；P1 的 `self` 与 `cross` 条件的提示词、判分器、请求参数完全一致，唯一变量是猜题方身份。
- 零失败：交叉盲测 597 条与自测 597 条均 `format_bad=0`、`error=0`；ICL 192 次调用同样零失败零格式异常。
- 凭据卫生：四家 API Key 仅在运行时由统一配置读取，不进入任何产物文件；全部交付物经泄露校验。

3.3 数据源与效度前置审计：C3/C4 在公开切片上被否决

数据底座为 CC-Riddle 全量 27,517 条（源文件 `CC-Riddle.jsonl`，2,863,919 字节，SHA256 `3654d163…bbacd`），按原文件顺序切成 28 批。我们对其做了完整分布统计，结果本身构成对「按顺序切片当随机划分」的警示：

表 3　全量数据分布审计

观察	实测	后果
来源随位置系统性变化	批 01–20（20,000 条）全为 `human`；批 21 为 385 `human` + 615 `gen`；批 22–28（6,517 条）全为 `gen`。合计 human 20,385 / gen 7,132	任何「前 N 批」抽样都把来源与位置完全混淆
答案字按位置聚集	批 01 仅 98 个不同答案字，批 19 为 452，批 20 为 599，批 27 为 353	按 id 顺序切片 ≠ 按答案字分层
100 题调试切片的答案分布	仅 11 个答案字（非 17、楂 16、杂 15、旦 15、霖 10、估 10、障 7、荤 5、顺 3、唠 1、傧 1）	准确率高度依赖答案先验，不可外推
公开集占比	`source_split`：train 50 / valid 35 / test 15；且 test 15 题答案字**全部为「旦」**	记忆污染与答案字单一双重混淆
全量 test 集的实际覆盖	`split=test` 且 `source=human` 共 3,831 条，覆盖 **981 个不同答案字**（最多「旦」31 条）；全量 source×split 为 human train 12,461 / valid 4,093 / test 3,831，gen train 4,165 / valid 1,387 / test 1,580	100 题切片的 11 个答案字远不足以代表 test 分布，必须按答案字分层重抽

四模型在这 100 题上的原始结果为 hy4 30%、U 26%、K 52%、DS 26%，但按 `source_split` 拆开后格局完全改变：

表 4　100 题四模型结果按原始划分分层（正确数/题数）

模型	train (50)	valid (35)	test (15)	合计
hy4	12/50 (24.0%)	12/35 (34.3%)	6/15 (40.0%)	30/100
u2-flash	7/50 (14.0%)	14/35 (40.0%)	5/15 (33.3%)	26/100
kimi-k3.1-pro	24/50 (48.0%)	22/35 (62.9%)	6/15 (40.0%)	52/100
deepseek-v4-pro	7/50 (14.0%)	12/35 (34.3%)	7/15 (46.7%)	26/100

K 的优势集中在公开 train/valid；在 15 题 test 子集上四家为 6/5/6/7，几乎持平（DS vs hy4、DS vs K 的 McNemar 均 p=1.000）。同时 100 题中四家全对 13 题、全错 41 题，猜测字发散到每家 56–71 个不同汉字。此外，四家「最高推理档」的语义互不相同：11-04 基线中只有 K 被强制开启原生思考（18.9 s/题、约 348 思考 token/题，输出 token 中思考占 84%），其余三家关闭思考（2–5 s/题、0 思考 token）；11-05 的 120 题最高档标定中单题探针耗时分别为 hy4 197.4 s、U 33.2 s、K 20.1 s、DS 171.8 s，四家合计输出 2,974,454 token（24,787/题），外推全量约 6.8 亿输出 token / 10–22 天，且该标定集 hy4 与 DS 分别有 55/120 与 53/120 条 402/超时异常。

裁定：这些数字同时违反 C3（公开集记忆污染、答案字聚集）与 C4（推理预算不对等使跨模型差值不可归因），因此不具备能力排名的效度。本文只把它们用作方法学背景，全部实证结论建立在「同一批题、条件间逐题配对」之上。这也解释了为何实验主体必须转向自行创作、可完全控制信息条件的题集。

3.4 自建题集：制谜协议与质检

为获得信息条件已知、来源可追溯、且不受公开集记忆污染影响的题目，我们构建了制谜流水线：

1. 目标字：按现代汉语高频序取 100 个单字（含部分独体字与 IDS 占位符情形，故 IDS 不作为权威字理）。
2. 参考素材：1,050 条既有谜面，其中 CC-Riddle 人工谜面 1,019 条、按字定向补缺的网络谜面 31 条；为每条补 1 条解释，其中 1,023 条由 LLM 在给定谜面 + 谜底条件下生成（事后解释），27 条为站点现成提示。

> 公开版口径注（2026-11-09）：上述 1,050 / 1,023 为构建期完整参考集的数字，本文所有统计均以此为准。31 条网络谜面在采集时标注「网络 UGC 转载，未取得明确授权；仅本地/受限研究使用」，配套数据集 CCRP DataSet v0.1 按方案 C 在导出发布包时将其与绑定的 27 条站点解析、4 条 LLM 解释、58 处网页链接一并下架，仅保留 SHA256 指纹；因此发布包的 `data/reference-slice.jsonl` 为 1,019 条、`data/explanations-llm.jsonl` 为 1,019 条。本地研究产物一条未删，指纹清单见 `data/WITHHELD.md`。这一差异不影响任何实验结论：600 条创作题、597 条闭环题与 192 次 ICL 调用经核验不含下架谜面文本。

1. 字理卡：拼音、笔画、部首、IDS 分解序列、高频序位；IDS 含占位符或独体不可分解者标记，不作为权威字理使用。

2. 创作：K 与 U 各 300 条，按手法均衡（拆形 / 会意 / 谐音各 200 条），每条指定目标字、手法，并附 4 条跨字示例与目标字的 IDS 卡；模型输出谜面、谜底与一段「解谜叙述」。三种手法使 C2 的结构化可分解性可被实测。
3. 质检：600 条中 597 条通过（3 条因疑似改写参考谜面或与既有谜面完全重合被拒）；最终泄底 0、长度违规 0。原创性 3-gram Jaccard 阈值 0.35 由 10 字试点 60 条分位数标定（p90=0、max=0.167）。
4. 溯源：CC-Riddle 来源给论文与仓库链接（数据集不含逐条 URL）、行 id、文件 SHA256、许可；网络来源给网页链接与片段哈希；模型生成内容无出处链接，只记录模型、prompt 版本、时间戳与输入快照哈希并标记 `no_url`，不伪造任何 URL。

表 5　自建题集产物

环节	数量	备注
参考谜面	1,050	1,019 CC-Riddle human + 31 web
解释	1,050	1,023 LLM 事后解释 + 27 站点现成
模型创作	600	K 300 / U 300；拆形 200 / 会意 200 / 谐音 200
质检通过	597	K 298 / U 299
进入盲测	597	拆形 197 / 会意 200 / 谐音 200

需要提请注意的两条审计事实，将在第 6.4 节用于训练适用性讨论：其一，1,023 条 LLM 解释中 602 条（58.9%）被模型自评 low，且手法自动分类严重偏向会意（594:427:2），说明「给定答案后补写解释」不是可靠的监督来源；其二，试点阶段从 `fkcmy.com` 抓取的 19 条「打一字」谜面中 16 条（84.2%）谜面与谜底同 CC-Riddle 完全一致，后续 43 条候选合并集中另有 12 条（27.9%）直接重复——各字谜站点与 CC-Riddle 同属转载链，泛爬整站并不能带来独立数据。

3.5 统计方法

- 区间估计：二项比例的 Wilson 95% 置信区间（Wilson, 1927）。
- 配对比较：同一 `gid` 两种条件的 0/1 结果构成配对四格，采用不一致格上的精确二项检验（McNemar, 1947 的双侧精确版本），而非正态近似。
- 组间构成比较：2×2 列联表采用 Fisher 精确检验（Fisher, 1922）。
- 效应分解：第 4.4 节的可加模型及恒等式推导见附录 B。
- 显著性口径：本报告全部 p 为双侧；不做事后多重比较校正，因此分层结果（尤其小样本 ICL 分层）只作方向性解读。所有原始逐题结果以 JSONL 留存，可复算。

---

4 实验一：生成–求解闭环

4.1 设计与判据对应



图 1　生成–求解闭环：出题期与答题期的信息条件

597 条通过质检的自创谜题，在两个条件下各答一次：

- 交叉盲测（cross，2026-11-05）：K 出题由 U 猜，U 出题由 K 猜。
- 同题自测（self，2026-11-06）：K 出题由 K 猜，U 出题由 U 猜；全新单轮对话，间隔一天，不带任何出题期上下文。

两条件共用提示词、判分器、并发策略与题集；`gid` 集合完全一致，构成 597 对逐题配对观测。设计意图是让「题目难度」在配对比较中被自动抵消，从而把差值归因于猜题方身份的变化。对探针判据而言，该设计同时操作了 C3（信息条件的隔离）与 C5（生成/求解两个方向的对照），第 4.4 节的 2×2 分解则承担 C4 的选择性识别。

4.2 总体结果

表 6　交叉盲测与同题自测总体

条件	正确 / 总数	猜中率	Wilson 95% CI
交叉盲测（A 出题 → B 猜）	233 / 597	39.03%	[35.20%, 43.00%]
同题自测（A 出题 → A 猜）	264 / 597	**44.22%**	[40.29%, 48.23%]
差值	+31	**+5.19 pp**	相对提升 13.3%

表 7　逐题配对四格（n=597）

	自测对	自测错	合计
交叉对	173	60	233
交叉错	91	273	364
合计	264	333	597

不一致格为 60（仅交叉对）与 91（仅自测对），精确二项检验 p=0.0144，在 α=0.05 下显著。两次作答的对/错一致率为 74.71%；给出同一个答案字的比例仅 36.35%（217/597，含都答错的同一个错字）。条件率上，`P(自测对 | 交叉对)=74.25%`，`P(自测对 | 交叉错)=25.00%`。

在解读前必须排除两种平凡解释。其一，记住谜底：自测是相隔一天、不同进程的全新会话，`messages` 中不含谜底与出题推理，`maker==guesser` 但 `history_messages=0`，因此答对不是从上下文复制答案。其二，题目信息不足：出题时模型持有目标字、IDS 卡、4 条跨字示例与指定手法，谜面正是它自己据此写出的；猜题时只缺这些信息，谜面本身完整。故两条件的差别只能来自「求解者是谁」（以及随之而来的内部表征差异）。权重层面的自我熟悉（同一模型既出题又答题）无法被完全排除，这是本文的重要局限，第 7 节详述。

4.3 分层结果：一个表观矛盾

表 8　按制谜方与手法分层

分层	n	交叉	自测	差值	McNemar *p*
K 出题	298	36.58%	58.05%	**+21.48 pp**	< 0.0001
U 出题	299	41.47%	30.43%	**−11.04 pp**	0.000142
拆形	197	49.75%	60.41%	+10.66 pp	**0.0139**
会意	200	35.00%	37.00%	+2.00 pp	0.665
谐音	200	32.50%	35.50%	+3.00 pp	0.405

按制谜方分层，两家方向完全相反且都显著；若草率解读，会得出「只有 K 认得自己的谜、U 反而更不认得」这种随模型而异的结论。按手法分层，则只有拆形的自测增益显著（+10.66 pp），会意与谐音均不显著；最突出的单格是 K 自猜拆形谜 48.98% → 84.69%（+35.71 pp）。手法给出了稳定且可解释的难度序（拆形 > 会意 ≈ 谐音），这是 C2 成立的直接证据。

4.4 2×2 全因子分解：方向相反是混淆，不是矛盾

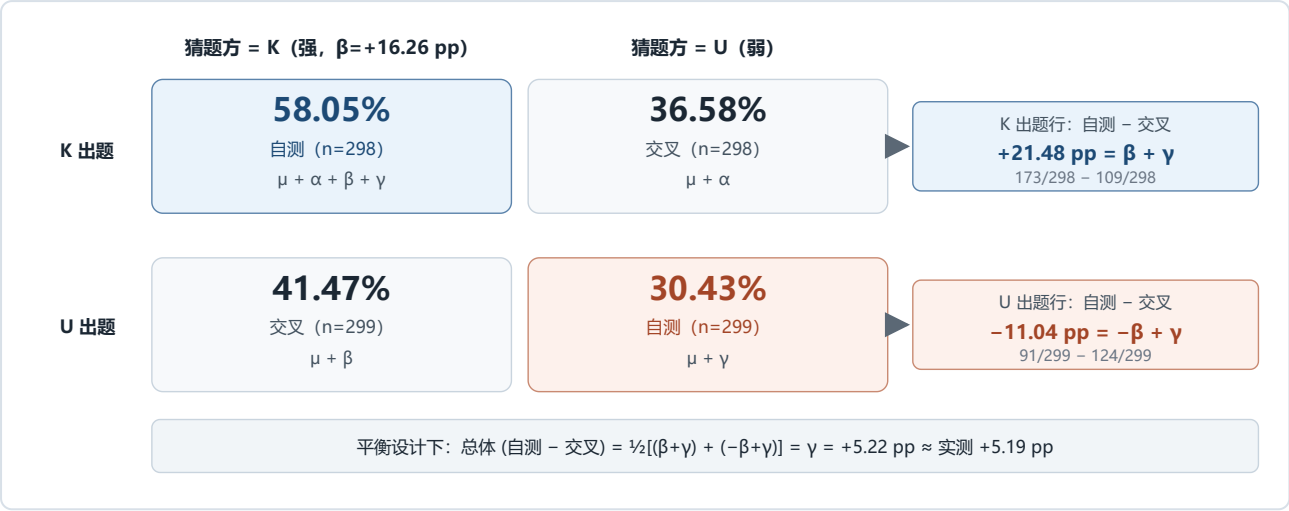


图 2　制谜方 × 猜题方 2×2 全因子：表观矛盾如何被 β 解释（差值为同一行内「自测 − 交叉」）

关键在于：按制谜方分层时，猜题方也被同时换掉了。K 出题时，自测意味着强猜手 K、交叉意味着弱猜手 U；U 出题时恰好倒过来。把两天的四个格子摊开，恰好构成一个近似完整的 2×2 全因子（制谜方 ∈ {K, U} × 猜题方 ∈ {K, U}）：

表 9　制谜方 × 猜题方四格（猜中率）

制谜方 \ 猜题方	K 猜	U 猜
K 出题 (n=298)	58.05%（自测）	36.58%（交叉）
U 出题 (n=299)	41.47%（交叉）	30.43%（自测）

设可加模型（推导见附录 B）：

```
rate = μ + α·1[题源=K] + β·1[猜题方=K] + γ·1[制谜方 = 猜题方]
```

由四格解得：μ=0.252149（U 出题 U 猜基线扣除 γ 后）、α=+0.113623（K 出题的题源更易猜）、β=+0.162566（K 的猜题能力高出 U 16.26 pp）、γ=+0.052199（自我熟悉净优势 5.22 pp）。以上均以原始计数之比计算、不预先舍入，推导见附录 B。

于是两个分层差值被完全解释：

- K 出题：自测 − 交叉 = (强猜手 + 自我) − (弱猜手) = β + γ = +21.48 pp √
- U 出题：自测 − 交叉 = (弱猜手 + 自我) − (强猜手) = −β + γ = −11.04 pp √

即两家模型共享同一个约 +5.2 pp 的自我优势，符号被 ±16.3 pp 的猜题能力差翻转。更重要的是恒等式：在平衡设计下，总体「自测 − 交叉」差值严格等于 γ；本实验两组 n=298/299 略有不平衡，故实测总体差值 +5.19 pp 与 γ=+5.22 pp 相差 0.03 pp，来自组大小与四舍五入。这意味着第 4.2 节的总体显著性检验，检验的正是 γ 本身，而非被主效应污染的混合物。

> 分解的边界（必须随结论一起报告）：这是描述性可加分解，不是回归估计；两组题源不同（K 298 条 / U 299 条），并非同一批题的严格重复测量；依赖「效应可加、无高阶交互」假设；未给出 γ 的置信区间。若 K 与 U 的自我优势强度实际不等（存在交互），γ 应读作两者的加权平均净效应。

从探针方法论看，这一节是 C4 的核心：若未把「生成方」与「评估方」作为两个独立因子交叉，任何「A 生成 → A 评估」型探针的读数都会被评估能力主效应污染。这正是 Hewitt & Liang（2019）所要求的选择性检验在行为层的对应物。

4.5 四格诊断：答对与答错各说明什么

把交叉/自测四格与手法、制谜方交叉，得到本文最核心的诊断材料：

表 10　作答四格 × 手法 × 制谜方

四格	n	拆形 / 会意 / 谐音	K 出题 / U 出题
都对	173	75 / 48 / 50	102 / 71
仅自测对	91	44 / 26 / 21	**71 / 20**
仅交叉对	60	23 / 22 / 15	**7 / 53**
都错	273	55 / 104 / 114	118 / 155

制谜方归属在「仅自测对」与「仅交叉对」两格间的差异极显著（K:U = 71:20 vs 7:53，Fisher $p=1.65\times10^{-12}$）：强模型出的题自己解得出，弱模型出的题反而别人更解得出。

答对（尤其 91 条「只有自己解得出」）说明什么。 出题期的输入是（目标字 + IDS 卡 + 4 条跨字示例 + 指定手法），答题期只剩谜面。谜面中编码的线索能被同一模型沿生成路径逆向还原为求解路径，说明生成策略与求解策略共享一套内部程序或风格约定，而非靠记忆。两个典型案例：

- 「衣裳同音，数数它最先」→ 谜底「一」：U 答「衣」，K 自答「一」（谐音指向的约定被出题者自己沿用）。
- 「卜字脚下添一横」→ 谜底「上」：U 答「下」，K 自答「上」（方位解释只在同一模型的生成/求解约定内自洽）。

答错（尤其 60 条「别人能解自己解不出」与 273 条都错）说明什么。 模型在有答案、有字理卡、有示例时能写出一段看似合理的解谜叙述；把这些信息撤走后，同一个模型却解不回自己刚造的谜。这提示那段叙述未必是可执行的求解程序，而更接近给定答案后的叙述化。典型案例：

- 「又去一点，添上一寸」→ 谜底「对」：U 答对，出题的 K 自答「夺」。
- 「九百六十万平方公里」→ 谜底「国」：U 答「国」，K 自答「垚」——自家先验反而把自己带偏。

手法层面：273 条都错中，会意 + 谐音占 218/273 = 79.85%，显著高于总体的 400/597 = 67.00%。开放式语义/语音联想是两家模型的共同盲区，而结构化拆形相对可迁移。

4.6 两处必须报告的负面结果

为避免把上述解释写成过度确定的结论，我们额外做了两项检验，结果不支持强解释：

表 11　负面结果检验

检验	数值	Fisher *p*	判定
「仅自测对」vs「仅交叉对」的拆形占比	44/91 (48.4%) vs 23/60 (38.3%)	**0.245**	不显著。可说的只是「总体增益按手法分解时拆形显著（表 8）」，**不能**说「自我优势集中在拆形」——两句话不是一回事
出题推理文本中直接出现谜底字的比例（至少一方解出 vs 都错）	293/324 (90.43%) vs 258/273 (94.51%)	**0.066**	仅为趋势；且方向是「都错组含谜底字更多」，不能作为「reasoning 是事后合理化」的硬证据

因此本文对 RQ1 的回答是有限度的：数据支持「生成 - 求解之间存在程序性不对称」，且这一不对称的方向可由「是否持有答案」预测；但「出题期 reasoning 纯属事后编造」这一强命题，在本数据中未被证实，需依靠第 5 节 ICL 的错误示例实验从另一角度提供证据。对 C5 而言，这一节只能给出间接证据。

---

5 实验二：ICL 控制任务

5.1 设计：控制任务与虚拟训练的双重角色

共用：4 条示例谜面 + 谜底（对 / 但 / 和 / 学）• 2 拆形 • 1 会意 • 1 谐音；示例字与 24 个测试字严格不相交

条件	assistant.reasoning	K 结果	U 结果
zero	k=0，无示例	41.67%	37.50%
answer	k=4，空（仅谜面→谜底）	41.67%	29.17%
program	k=4，人工可执行拆解（正确）	45.83%	37.50%
self	k=4，模型自己给定谜底后写的事后解释	45.83%（4 条全对）	20.83%（含 1 条误拆）

program vs self 的 prompt 仅差推理文本（712.5 vs 739.5 token）；U 的 4:0 单向优势把「正确性」与「自我性」分离

图 3　ICL 控制任务：同一批示例谜面，仅替换 assistant 推理内容的来源

P1 显示缺口位于「只给谜面时的逆向执行」。RQ3 追问：不改动权重、仅在上下文里给解谜示例，能否激活该能力？若能，说明权重里已有能力、缺的只是任务格式对齐；若不能，则更可能需要权重层的结构表征注入。就探针判据而言，这一节同时承担两个角色：作为控制任务检验 C4（把格式效应、示例来源与推理正确性分开），作为无需改权重的虚拟训练为 C5 提供方向性证据。

题集：从 597 题按（制谜方 × 手法）分层抽 24 题（K/U × 拆形/会意/谐音，每格 4 题），固定种子 20261106，题集 SHA256 `b16111d9…8537f` 冻结。示例字 {对，但，和，学} 与 24 个测试字严格不相交，沿用留出隔离纪律，杜绝示例直接泄露谜底。

四条件（`zero` / `answer` / `program` / `self`）：后三者共用完全相同的 4 条谜面与谜底（2 拆形 / 1 会意 / 1 谐音，均取自 K 的创作），唯一差别是 `assistant` 回复中的推理内容：

表 12　ICL 四条件

条件	k	`assistant.reasoning` 内容	平均 prompt token
`zero`	0	无示例（同批基线）	279.0
`answer`	4	空（仅谜面 → 谜底），控消息结构与长度	538.0
`program`	4	人工编写的**可执行**拆解步骤	712.5
`self`	4	**该模型自己**在给定谜底后写的事后解释	739.5

`program` 与 `self` 的谜面、答案、消息结构、系统提示、采样参数完全相同，prompt 长度 712.5 vs 739.5 token，长度差异仅来自推理文本本身——这是整套实验中最干净的对照：唯一实质变量是「推理内容由谁写、写得对不对」。

示例谜面举例（拆形）：「旭日初升人独立」→ 但。人工程序推理为：「旭日初升」给出「日」与地平线一横，上下叠成「旦」；「人独立」取单人旁「亻」；左右并置得「但」。

5.2 结果

192 次调用（2 模型 × 24 题 × 4 条件），零失败、零格式异常，累计请求耗时 1,983.1 s（3 并发，墙钟约 11 分钟），输入 108,912 token、输出 61,720 token。

表 13　ICL 主结果（正确数 / 24，猜中率）

模型	`zero`	`answer`	`program`	`self`
kimi-k3.1-pro	10/24 (41.67%)	10/24 (41.67%)	11/24 (**45.83%**)	11/24 (**45.83%**)
u2-flash	9/24 (37.50%)	7/24 (29.17%)	9/24 (37.50%)	5/24 (**20.83%**)

没有任何一个条件与 `zero` 的差异达到显著（最小 p=0.125，n=24 每格仅 8 题）。按手法分层后，`program − answer` 的增益散落在拆形与谐音（三格 +12.5 pp：K×谐音、U×拆形、U×谐音），而会意题在 `zero` / `answer` / `program` 三个条件下完全不动（K 会意恒为 25.0%，U 会意恒 ≤12.5%），仅 K 的 `self` 条件有 1 题波动（25.0%→37.5%，不显著）。

预测 P1「增益集中在拆形」未获验证；但换一个读法更有价值：会意题在四个条件下几乎纹丝不动，说明开放式语义联想不是 few-shot 能激活的能力。

5.3 天然对照：一条错误解释如何拖垮整个条件

`prepare` 阶段出现了一个非设计使然、却极具解释力的对照：K 与 U 各自为 4 条示例谜面写事后解释时，K 的 4 条全部正确，而 U 的「旭日初升人独立」一条写错了字形拆解：

> U 的自写解释：「谜面『旭日初升』取『旭』字去掉『日』（初升的太阳），剩『九』；『人独立』表示『人』字独立站立，可变形为『亻』。『九』与『亻』组合，即为『但』字。」
> 正确的程序：「日 + 一 = 旦」；「亻 + 旦 = 但」。
> K 的自写解释：「『旭日初升』会意为『旦』，即太阳从地平线上升起；『人独立』提示单立人『亻』。将『亻』与『旦』左右组合，便成谜底『但』。」（正确）

于是两家 `self` 条件相对 `program` 的表现恰好分叉：

表 14　关键直接对照（配对四格）

模型	对照	仅 A 对	仅 B 对	都对	都错	McNemar *p*
kimi	`program` vs `self`	1	1	10	12	1.000
kimi	`program` vs `answer`	1	0	10	13	1.000
u2	**`program` vs `self`**	**4**	**0**	5	15	**0.125**
u2	`program` vs `answer`	4	2	5	13	0.6875

K 的 `self` 与 `program` 完全持平（45.83%），U 的 `self` 掉到 20.83%——比 `zero` 低 16.67 pp，比 `program` 低 16.67 pp，`program` 对 `self` 为 4:0 的单向优势。由于两条件除推理文本外完全相同，最简解释是：示例里那条错误的字形拆解被模型当作可复用的程序学进去了，而不是「自己的解释天然更亲和」。附带一个反直觉观察：仅给（谜面，谜底）的 `answer` 对 U 是干扰（29.17%），加上程序脚手架才回到 37.50%。

这条证据同时补上了第 4.6 节留下的缺口：4.5 节只能说「给定答案后的叙述未必可执行」，Fisher p=0.066 不足以证实；而本节表明，一旦把这类叙述作为上下文示范，其中的错误会直接转化为求解错误。它支持「事后解释不宜默认为监督信号」的推论，但请注意，这仍是单次、单条错误示例的观察，且 p=0.125 不显著。就 C5 而言，这属于方向性证据而非判定性证据。

5.4 复现性：日间漂移比预期更小

为量化单次采样噪声（C6），我们把 ICL 的 `zero` 条件与 11-06 自测中严格同模型同题的 12 题比对（早期版本曾误把 11-06 中由另一模型作答的题也纳入对比，已修正口径）：

模型	n	判定一致	一致率	zero	11-06 自测
kimi	12	12	**100%**	33.33%	33.33%
u2	12	9	75%	33.33%	25.00%

K 隔一天完全复现，U 有三题翻转。这说明本实验的采样波动小于常见担忧，P1 的 597 条配对结果具有较好的重测稳定性；但 n=12 仍不足以给出紧的方差估计，第 7 节仍把「单次采样」列为局限。

5.5 三个可证伪预测的判定

表 15　实验前预测与判定

预测	判定	说明
P1 程序示例的增益集中在拆形	**未验证**	增益散在拆形/谐音；但会意在 `zero` / `answer` / `program` 三条件下零增益，可作为「开放式联想难以由 few-shot 激活」的方向性证据
P2 事后解释不优于可执行拆解	**方向支持**	与示例解释的正确性一一对应（K 全对→持平；U 含 1 错→−16.7 pp），而非与「是否自源」对应
P3 单次采样噪声大、结果不可复现	**反向支持**	严格同模型同题下 K 100%、U 75% 复现

6 综合裁定：字谜能否成为结构探针

6.1 判据逐条裁定



图 4　有效性裁定流程：六条判据 → 三套探针 → 三种用法

把第 3–5 节的证据按表 1 的六条判据归拢，得到对题目的直接回答：

表 16　六条判据的逐条裁定

判据	关键证据	裁定
C1 客观可判分	单字精确匹配；1,194 次闭环作答 + 192 次 ICL 零格式异常；无评判者、无偏好对、无量规	**满足**
C2 结构化可分解	三手法给出稳定难度序（49.75% / 35.00% / 32.50%）；都错格 79.85% 为会意+谐音；生成/求解两方向可分别操纵	**满足**
C3 信息条件可控	自建 597 题：出题期持字理卡与答案，答题期仅谜面、隔一天、全新单轮；但公开 100 题切片仅 11 个答案字、85/100 来自 train/valid、test 15 题全为「旦」	**分场景**：自建题集满足，公开切片不满足
C4 选择性	2×2 全因子把 β=+16.26 pp 从分层差值中分离，剩 γ=+5.22 pp；ICL 同谜面仅换推理来源（712.5 vs 739.5 token）。但四家推理预算不对等、无人类基线、无多次采样	**部分满足**：题内对照充分，跨模型对照不足
C5 能力层可区分	ICL 192 次调用，`program` vs `self` 4:0、会意题三条件零增益；但所有 McNemar p≥0.125	**未达标**（仅方向性信号）
C6 可复现可审计	seed 20261106 + SHA256 冻结、prompt 版本固定、逐题 JSONL 留存、三级溯源与 `no_url` 标记；日间复现 K 100% / U 75%	**满足**

因此答案不是二值的。C1/C2/C6 三条「资格判据」全部满足，这在中文能力诊断任务中并不常见：多数任务要么依赖主观评分（C1），要么只有一个总分（C2），要么无法逐题复算（C6）。C3/C4 是分水岭：一旦换成自建、配对、可交叉的题集，字谜的读数可以归因；沿用公开切片则不能。C5 是当前唯一硬缺口，它决定了探针能否外推到训练。

> 一个额外的元发现：探针本身也会被「自我熟悉」污染。+5.22 pp 的 γ 意味着，任何「模型自己生成题目 → 自己或同系列模型评估」的探针设计，若未交叉生成方与评估方，读数里都会混入这一净优势。这可以看作对 control-task 方法论在生成式评测场景下的一个具体补充。

6.2 三种用法，三种结论

「能否成为结构探针」还取决于「拿来做什么」。同一批数据在不同用法下裁定不同：

表 17　三种用法的裁定

用法	读数的含义	裁定	依据
诊断型结构探针	同一批题、同一判分器下的**条件间配对差**	**能**	C1/C2/C6 满足，C3/C4 在自建闭环题集内满足；照出三类能力缺口与一个可分离的偏差
排名型基准	跨模型总体准确率	**不能**（现有切片）	表 3 / 表 4：11 个答案字、记忆污染、推理预算不对等；四家在 15 题 test 上 6/5/6/7 持平
训练信号探针	SFT / 数据构造的因果效应	**尚不能判定**	无任何训练实验；ICL 只是无需改权重的替代观察，且全部 $p \geq 0.125$

三者不可互相替代：把诊断型探针的配对差当作排名，或把 ICL 的方向性信号当作训练有效性结论，都是对读数的误用。

6.3 探针照出的能力结构

汉字结构知识是「可描述但不可执行」的。 CC-Riddle 原论文已指出模型在字谜任务上表现不佳。本文从生成 - 求解闭环给出互补证据：模型能谈论「木 + 目 = 相」这类结构关系，甚至在持有答案与 IDS 卡时写出完整的解谜叙述；但当输入收缩为一句谜面时，同一模型无法稳定执行反向搜索。用 knowing-that / knowing-how 的区分（Ryle, 1949）表述，观察到的是陈述性描述与程序性执行之间的断裂，而非单纯的「不知道字形」。三个观测共同指向这一点：① 597 条中 273 条两家都错（45.7%）；② 60 条「别人能解、出题者自己解不出」；③ 出题推理含谜底字的比例与可解性的关系 p=0.066、方向甚至相反。必须克制的是：我们没有做推理链的人工逐条标注，无法给出「多少比例的 reasoning 是伪程序」这类定量结论。

自我偏好可以在客观判分任务上被量化并分离。 已有 self-preference 研究多建立在主观打分、偏好对或自评之上，评判工具本身携带偏差。本文把评判环节完全去掉，仍观测到 +5.22 pp 的净自我优势（配对 p=0.0144），说明该现象不是 LLM-as-judge 的度量伪影。方法上更值得强调的是识别策略：如果只按制谜方分层，会得到「K +21.5 pp、U −11.0 pp」这一看似随模型而异、难以解释的读数；把制谜方 × 猜题方做成 2×2 全因子后，表观矛盾被 $\beta = +16.26$ pp 完全解释，剩下共同的 $\gamma = +5.22$ pp。

手法分层：结构化可迁移，开放式是共同盲区。 三层结果一致：交叉盲测中拆形 49.75% > 会意 35.00% > 谐音 32.50%；总体自测增益按手法分解只有拆形显著（+10.66 pp, p=0.0139）；都错格中会意+谐音占 79.85%（总体 67.00%）；ICL 中会意在 `zero` / `answer` / `program` 三条件下完全不动。合起来可读作：依赖离散字形操作的线索相对容易被形式化、也相对容易跨模型迁移；依赖语义别解、文化常识与声调联想的线索是两家模型的共同地板。这与 CC-Riddle 原论文强调「字谜需要字形、常识与比喻语言的综合」一致，并进一步指出三者的难度并不对等。同样要克制：第 4.6 节已说明「自我优势集中在拆形」在四格占比层面不成立（Fisher p=0.245）。

6.4 对训练数据设计的含义：三条可证伪假设（非实证结论）

本课题最初的问题之一是「这类数据对训练有什么价值」。本文没有做任何 SFT、消融、训练曲线或下游迁移实验，因此不给出任何训练有效性结论，也不认为 C5 已达标。 但把前述三类实证并置，可以把「训练价值」改写为带观测锚点的假设，并明确其证伪条件：

表 18　由观测支撑的训练假设与证伪路径

#	观测锚点	假设	证伪条件
H1 监督信号必须是可执行且经校验的步骤	ICL 中 1 条错误自解释使 U 掉 16.7 pp（`program` vs `self` 4:0）；1,023 条事后解释 58.9% 自评 low	用 `（谜面，事后解释，谜底）` 做 SFT 会教模型编理由；应改用 `（谜面，可执行拆解，谜底）`，且拆解须能被程序或人工校验	若用校验后的步骤训练与用未校验解释训练，在留出集上无差异，H1 被证伪
H2 仅 `（谜面，谜底）` 对弱模型可能有害	U 的 `answer` 条件 29.17% < `zero` 37.50%，补上程序脚手架才回到 37.50%	弱模型需要过程监督而非纯标签监督；纯标签对齐可能挤占本已脆弱的求解路径	若扩大到 120 题后 `answer` 与 `zero` 无差异或反超，H2 被证伪
H3 会意/谐音缺口可能不在格式层	会意题在程序示例条件下零增益；都错格 79.85% 为会意+谐音	这部分能力更可能需要权重层注入（结构/音韵表征、别解训练数据），few-shot 无法激活	若在 k=2/4/8 梯度、含高质量会意程序示例下出现显著增益，H3 被削弱

此外有三条训练/评测数据构造层面的风险，均有本数据实证支撑，可作为协议建议而非效果宣称：

1. 泄漏风险：试点网络素材 84.2%（16/19）与 CC-Riddle 转载链完全一致、合并集另有 12/43 直接重复，且公开 split 未按答案字隔离（test 15 题答案全为「旦」）。用这类语料扩充训练集并沿用原 split 评测，会同时引入记忆污染与分布泄漏。
2. 监督信号风险：给定谜面 + 谜底补写的解释本质是事后合理化（58.9% 自评 low，手法自动分类偏会意 594:427:2）。把它当 CoT 监督，等于优化「叙述的合理性」而非「求解的可执行性」。
3. 合成数据反馈循环：自出题自答存在 +5.22 pp 净自我优势。若用某模型生成题目/解释，再让同系列模型自评或自测，会系统性高估其能力；评测协议应强制生成方与评估方交叉（见 4.4 与 6.1）。

对「ICL 提得动 / 提不动」的判读规则也在此明确：提得动 ⇒ 权重里已有能力，训练只需任务格式对齐；提不动 ⇒ 更可能需要权重层注入，且训练数据须是可执行步骤。本文 24 题探针尚不足以判定属于哪一种（所有 $p \geq 0.125$），因此 H1 – H3 全部保留为待检验假设。

6.5 让字谜成为更好探针的协议建议

针对未达标的判据，补齐路径如下：

1. 补 C3：重建题集时按答案字分层、固定种子、SHA256 冻结，并从 `split=test` 的 3,831 条人工题中取；不要把按 id 顺序的前 N 批当随机样本（表 3）。冻结 1000 条分层 test 集是当前最高优先级的下一步。
2. 补 C4（跨模型）：把「是否开启原生思考」作为独立实验变量单独报告，或至少并列标注耗时与思考 token；四家「最高档」语义不同，直接比较会重新引入 11-04 的预算不对等。并补人类基线与多次重复采样。
3. 补 C4（设计）：生成 – 评估型实验必须交叉生成方与评估方两个因子，并报告配对不一致格与精确检验，而非只给总体准确率。

4. 补 C5：把 ICL 矩阵扩到 120 题（4 类示例 × k=0/2/4）以给出有意义的 p 值，并补人工对「解谜叙述是否可执行」的逐条标注；若条件允许，再做真实 SFT 消融。
5. 保持 C1/C6：继续报告负面结果与所有分层，避免只展示显著子组（表 11、表 15 即为示范）；溯源分级为数据集来源给论文/仓库 + 行 id + 文件哈希、网页来源给链接 + 片段哈希、模型生成内容标记 `no_url`，绝不伪造 URL。

---

7 局限

实验规模与显著性。 ICL 探针仅 24 题、每手法每格 8 题、单次采样，192 次调用中所有 McNemar $p \geq 0.125$，第 5.3 节的核心对照也只是方向性信号；这正是 C5 未达标的直接原因。要给出有意义的 p 值，需扩到 120 题完整矩阵（4 类示例 × k=0/2/4）。第 4 节的 597 条配对是本文唯一达到统计显著的结果。

模型覆盖。 闭环实验只有 K 与 U 两个中文商用 API；hy4 与 DS 因 HTTP 402 额度耗尽未参与（标定集中两家分别有 55/120、53/120 条异常）。无开源模型、无海外模型、无人类基线、无多次重复采样。因此本文不主张任何跨厂商或跨语种的普遍性，C4 的跨模型部分也因此只能判为「部分满足」。

设计层面。 ① 2×2 分解为描述性可加模型，两组题源不同（298/299）非严格配对，依赖无交互假设，未估 γ 的置信区间；② 权重层面的自我熟悉无法排除——同一模型既出题又答题，「全新对话」只清除了上下文，未清除权重；③ 示例谜面全部取自 K 的创作，可能对 K 存在风格优势；④ `zero` 与 few-shot 的消息轮数不同（ICL 固有），`answer` 条件仅部分控制；⑤ 人工程序示例只有 4 条、无 k 梯度；⑥ 两次实验相隔一天，模型版本可能变化；⑦ 出题期未采集人工对「解谜叙述是否可执行」的逐条标注。

题集层面。 ① 597 题覆盖 100 个高频字，不含低频字与繁体；② 全部为 zero-shot 解谜，制谜阶段用的 4 条跨字示例不进入答题；③ 质检以自动规则 + 3-gram Jaccard 原创性阈值（0.35，由 60 条试点标定）为主，未做人工谜面质量与谜底唯一性评审，这是当前最大缺口；④ 解释均为事后合理化或站点现成提示，非权威字理；⑤ 会意/谐音可能存在地板效应，压缩了 ICL 增益的可观测空间；⑥ 字义字段未按原计划补充，会意手法受限。

术语与外推边界。 本文的「结构探针」是行为层探针，不提供内部表征层面的证据；C1 – C6 判据是为汉字结构化操作任务定制的，是否适用于其他语言或任务需另行检验。

数据与伦理。 本文配套数据集以「汉字字谜探针数据集 / Chinese Character Riddle Probes Dataset（CCRP DataSet）v0.1」于 2026-11-09 公开发布，发布者春芽数源（Spring Buds Data Source Inc.）。按目录分层许可：`data/` 为 CC BY-NC-SA 4.0（非商业、署名、相同方式共享，继承上游 CC-Riddle 的许可；§4(b) 数据库权使含其实质内容的数据库构成 Adapted Material），`scripts/` 为 MIT，`paper/` 与文档为 CC BY 4.0；上游三位作者的完整署名、许可链接、原库 URI 与「已做选取、重排、补解释」的修改声明见仓库 `THIRD_PARTY.md`。CC BY-NC-SA 4.0 不是 OSI 认证的开源许可；免费公开仓库本身属 §1 定义的非商业行为，NC 约束的是下游商业使用。构建期参考集中的 31 条网络 UGC 谜面自带「仅本地/受限研究使用」标记，按方案 C 未随包发布，仅保留 SHA256 指纹

（`data/WITHHELD.md`）；本地研究产物一条未删，离线站点与小游戏仍为本地/受限访问、不对外发布。全部公开产物经扫描不含明文凭据、不含本机绝对路径、不含第三方网页链接。本文未使用人类被试数据。

---

8 结论

汉字字谜能成为大语言模型的结构探针，但只在特定用法与特定题集条件下成立。

按六条有效性判据逐条检验：C1（客观可判分）、C2（结构化可分解）、C6（可复现可审计）完全满足；C3（信息条件可控）与 C4（选择性）在自建的 597 题闭环题集上成立、却被现成公开切片否决；C5（能力层可区分）目前只有方向性证据，是唯一硬缺口。因此，作为诊断型结构探针：能——它以单字精确匹配、三手法正交分解、生成/求解可逆闭环与 2×2 交叉控制，照出了三类能力结构：汉字结构知识「可描述但不可执行」、生成－求解不对称、以及 +5.22 pp 的自我熟悉偏差（后者若不作因子分离会被 ±16.26 pp 的猜题能力差翻转符号）；作为排名型基准：不能——11 个答案字、记忆污染与推理预算不对等使跨模型分数不可归因；作为训练信号探针：尚不能判定——ICL 控制任务虽给出「示例效果取决于推理正确性而非自我性」的干净对照，但全部 $p \geq 0.125$，且无任何训练实验。

由此，本文对题目给出一个可复核的裁定，同时给出使它从「有条件肯定」走向「无条件肯定」的路径：冻结 1000 条按答案字分层的 test 集（补 C3）、控制推理预算并补人类基线与多次采样（补 C4）、把 ICL 矩阵扩到 120 题并补人工推理链标注与真实 SFT 消融（补 C5）。此外，本文的方法论副产品具有超出字谜的适用性：任何「模型生成 → 模型评估」型探针，若未把生成方与评估方作为独立因子交叉，其读数都可能被评估能力主效应与自我熟悉净效应污染。

参考文献

1. Xu F, Zhang Y, Wan X. CC-Riddle: A Question Answering Dataset of Chinese Character Riddles. arXiv preprint arXiv:2206.13778, 2022（v2 修订于 2023-09-24）. 数据集：github.com/pku0xff/CC-Riddle.
2. Halder D, Saji A, Jayakumar T, Puduppully R, Kunchukuttan A, Dabre R. RiddleBench: A New Generative Reasoning Benchmark for LLMs. arXiv preprint arXiv:2510.24932, 2025.
3. Hu H, Song S, Shao C, Zhang K, Zhu T, Zhao X. Reasoning or Memorization: Can LLMs Understand and Generate Chinese Xiehouyu Riddles? arXiv preprint arXiv:2607.23440, 2026.
4. Zheng L, Chiang W-L, Sheng Y, et al. Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena. NeurIPS 2023 Datasets and Benchmarks Track; arXiv:2306.05685, 2023.

5. Hewitt J, Manning C D. A Structural Probe for Finding Syntax in Word Representations. Proceedings of NAACL-HLT 2019, Volume 1: 4129–4138; DOI 10.18653/v1/N19-1419.
6. Hewitt J, Liang P. Designing and Interpreting Probes with Control Tasks. Proceedings of EMNLP-IJCNLP 2019: 2733–2743; DOI 10.18653/v1/D19-1275.
7. Belinkov Y. Probing Classifiers: Promises, Shortcomings, and Advances. Computational Linguistics, 48(1): 207–219, 2022; DOI 10.1162/coli_a_00422.
8. Brown T B, Mann B, Ryder N, et al. Language Models are Few-Shot Learners. Advances in Neural Information Processing Systems 33: 1877–1901, 2020.
9. Wei J, Wang X, Schuurmans D, et al. Chain-of-Thought Prompting Elicits Reasoning in Large Language Models. Advances in Neural Information Processing Systems 35, 2022; arXiv:2201.11903.
10. Ryle G. The Concept of Mind. London: Hutchinson, 1949.（knowing-that / knowing-how 区分）
11. Wilson E B. Probable Inference, the Law of Succession, and Statistical Inference. Journal of the American Statistical Association, 22(158): 209–212, 1927.
12. McNemar Q. Note on the Sampling Error of the Difference between Correlated Proportions or Percentages. Psychometrika, 12(2): 153–157, 1947.
13. Fisher R A. On the Interpretation of χ^2 from Contingency Tables, and the Calculation of P. Journal of the Royal Statistical Society, 85(1): 87–94, 1922.

> 文献 1–9、11–13 的书目信息已于 2026-11-06 通过公开检索逐条核对（其中 5–7 为本轮改题新增，卷期与页码取自 ACL Anthology / MIT Press 正式条目）；文献 4 的作者列表按惯例以 et al. 简写，投稿前请按目标格式补全。文献 10 为哲学经典，仅用于概念区分，未引用具体页码。

附录 A　数据口径与可复现性

产物清单（按公开版 CCRP DataSet v0.1 仓库相对路径重列；逐文件字节数与 SHA256 见 `manifest.json`，字段字典见 `data/README.md`）

文件	内容
`data/reference-slice.jsonl`	1,019 条 CC-Riddle 派生参考谜面与结构卡（构建期参考集为 1,050 条）
`data/explanations-llm.jsonl`	1,019 条对应的 LLM 解释（构建期 1,023 条）
`data/provenance-reference.jsonl`	参考谜面逐条溯源（上游行 id、源文件 SHA256、许可）
`data/WITHHELD.md`	31 条下架记录的 SHA256 指纹清单，不含谜面文本与网页链接
`data/generated-{kimi,u2}.jsonl`	600 条创作及出题期 reasoning
`data/quality.jsonl`	600 条质检裁决
`data/blind.jsonl`	597 条交叉盲测
`data/blind-self.jsonl`	597 条同题自测，含 `conversation` 口径字段
`data/selftest-analysis.json`	配对统计、分层、2×2 分解
`data/icl-probe-{items.jsonl,examples.json,jsonl}`	24 题冻结集、4 条示例、192 次调用
`data/icl-probe-analysis.json`	ICL 主表、分层、关键对照、设计元数据
`data/{provenance-generated,selftest-provenance}.jsonl`	创作题与自测的溯源凭证（`no_url` 标记、输入快照哈希）
`data/summary.json`	流水线汇总与局限声明

> §3.3 使用的 100 题四模型综合结果、120 题最高档标定与 27,517 条全量切片审计，属评测集有效性审计的本地中间产物，未随 CCRP DataSet v0.1 发布；其数字可依 §3.3 所述口径从上游公开语料 CC-Riddle 复算。构建期 `03_prompt/` 快照与离线站点同理，留在本地受限研究环境。发布包的 `input_snapshot_sha256` 保证创作条件仍可校验。

可复现性要点：题集 seed 20261106、SHA256 `b16111d96d4609ae43d3d59824196342ae31178654aff366224e88597af8537f`；制谜 prompt 版本 `riddle-gen-skill-v0.2-full100`；全量源文件 SHA256 `3654d163f026e75702d7fccfe52afa21ee2bbb28019c8420720b02a991abbacd`；所有 LLM 生成内容记录模型 / prompt 版本 / 时间戳 / 输入快照哈希。驱动脚本：`riddle_gen_run.py`（制谜与交叉盲测）、`riddle_gen_selftest.py`（自测、配对分析、站点渲染）、`riddle_gen_icl_probe.py`（ICL 探针），三者互不覆盖、旧产物零改动。重渲染站点请用 **`riddle_gen_selftest.py --stage site`**，仅运行旧脚本的 `--stage site` 会回退到不含自测的版本。

API 调用量：交叉盲测 597 次（累计 6,204.9 s）、同题自测 597 次（累计 5,164.1 s，3 并发墙钟 28m39s）、ICL 192 次（累计 1,983.1 s，墙钟约 11 分钟）；全部零失败、零格式异常。

附录 B　2×2 可加分解推导

记四格观测率（表 9）。以下一律使用原始计数之比，不预先舍入：

- `r(K,K) = 173/298 = 0.580537`
- `r(K,U) = 109/298 = 0.365772`
- `r(U,K) = 124/299 = 0.414716`
- `r(U,U) = 91/299 = 0.304348`

模型 `rate = μ + α·1[题源=K] + β·1[猜题方=K] + γ·1[制谜方=猜题方]` 给出：

```
r(K,K) = μ + α + β + γ
r(K,U) = μ + α
r(U,K) = μ + β
r(U,U) = μ + γ
```

由后三式得 `α = r(K,U) − μ`、`β = r(U,K) − μ`、`γ = r(U,U) − μ`，代入第一式：

```
μ = [r(K,U) + r(U,K) + r(U,U) − r(K,K)] / 2
  = (0.365772 + 0.414716 + 0.304348 − 0.580537) / 2 = 0.252149
```

故 `α = 0.113623`（+11.36 pp）、`β = 0.162566`（+16.26 pp）、`γ = 0.052199`（+5.22 pp）。分层差值：

```
K 出题：r(K,K) − r(K,U) = β + γ = 0.214765 = +21.48 pp
U 出题：r(U,U) − r(U,K) = −β + γ = −0.110368 = −11.04 pp
```

两个等式在精确计数下严格成立（$\beta+\gamma$ 与 $-\beta+\gamma$ 恰等于两行差值），不存在近似。

> 口径说明：配套分析文件 `selftest-analysis.json` 与离线站点采用「先把率四舍五入到四位小数再运算」，得 `α=0.11365`、`β=0.16255`、`γ=0.05215`、K 行差 `+21.47 pp`。两种口径最多相差 0.01 pp，不改变任何结论；本文正文统一采用精确计数口径。

恒等式：在每组题数相等（n_K = n_U）时，

```
总体差值 = ½[(β+γ) + (−β+γ)] = γ
```

本实验 n_K=298、n_U=299，故实测差值 +5.19 pp 与 γ=+5.22 pp 相差 0.03 pp。这说明第 4.2 节对总体差值做的 McNemar 检验，检验对象本质上就是 γ。

附录 C　典型案例索引

类型	谜面	谜底	交叉作答	自测作答	出处
仅自测对	衣裳同音，数数它最先	一	U 答「衣」	K 自答「一」	`blind*.jsonl`
仅自测对	卜字脚下添一横	上	U 答「下」	K 自答「上」	同上
仅交叉对	叉去一点，添上一寸	对	U 答「对」	K 自答「夺」	同上
仅交叉对	九百六十万平方公里	国	U 答「国」	K 自答「垚」	同上
ICL 错误示例	旭日初升人独立	但	—	U 自写解释误拆为「旭去日 = 九」	`icl-probe-examples.json`

本文所有数字均于 2026-11-06 从工作区产物回读复核；不含任何明文凭据，不含伪造 URL。